

**UNIVERSIDAD AUTONOMA DE MANIZALES**

Facultad de Ingeniería / Ciencias Económicas

Programa Académico

**ANALÍTICA AUTOMATIZADA DE E-COMMERCE  
COLOMBIA CON LLM**

*Integración de modelos de lenguaje para análisis de ventas 2022-2023*

**Presentado por:**

Julian Andres Cardona Alzate

Actividad 4 — Big Data

Colombia  
2026

## RESUMEN

El presente informe analiza 300,000 órdenes de comercio electrónico en Colombia (2022-2023), con un ingreso total de \$1,061 millones y un ticket promedio de \$3,537. Se implementó un pipeline con PySpark para el procesamiento de datos, se calcularon agregaciones estadísticas por categoría, ciudad, método de pago y periodo, y se conectó la API de OpenAI (GPT-4o-mini) para generar un reporte analítico automatizado. Los resultados se presentan en un dashboard interactivo construido con Streamlit y Plotly. El informe combina la generación automática del modelo con el juicio crítico del analista, evidenciando tanto las capacidades como las limitaciones actuales de los LLM aplicados a la analítica de datos.

**Palabras clave:** Big Data, LLM, e-commerce, PySpark, OpenAI, Colombia, Streamlit.

## 1. INTRODUCCIÓN

El comercio electrónico en Colombia ha crecido de forma sostenida, impulsado por la expansión de la conectividad y el auge de las billeteras digitales. Esta actividad tiene como objetivo explorar el uso de modelos de lenguaje de gran escala (LLM) conectados desde Python para realizar analítica automatizada y redacción asistida de reportes, combinando la inteligencia artificial con el criterio del analista humano.

El dataset contiene 300,000 órdenes en 7 categorías de producto, 10 ciudades colombianas y 5 métodos de pago, registradas entre enero de 2022 y diciembre de 2023. El pipeline implementado comprende tres etapas: (1) procesamiento y limpieza con PySpark, (2) cálculo de agregaciones estadísticas, y (3) envío del resumen estructurado a GPT-4o-mini para obtener el reporte analítico automatizado.

## 2. METODOLOGÍA

Se utilizó Python como lenguaje principal con PySpark para el procesamiento distribuido del dataset CSV (31 MB, 300,000 registros). La limpieza incluyó imputación de nulos (calificación reemplazada por la media de 3.62; descuento\_pct por 0), eliminación de registros con precio o cantidad no positivos, y creación de columnas derivadas: total\_venta, tiene\_descuento, anio, mes, hora y ruta ciudad-departamento.

Las agregaciones se exportaron como archivos CSV por categoría, ciudad, método de pago, periodo mensual y estado de envío. Se construyó un prompt estructurado con el resumen estadístico y se envió a la API de OpenAI solicitando estadísticas descriptivas, patrones y recomendaciones. Las librerías utilizadas fueron: pandas, pyspark, openai, streamlit, plotly, matplotlib y reportlab.

## 3. REPORTE ANALÍTICO GENERADO POR EL LLM

A continuación se presenta el reporte generado automáticamente por el modelo GPT-4o-mini a partir del resumen estadístico del dataset. Se transcribe sin modificaciones para preservar la integridad del análisis automatizado.

Reporte Analítico — E-Commerce Colombia 2022-2023 Generado automáticamente por GPT-4o-mini Dataset: 300,000 órdenes · Colombia · 2022-2023 Ingreso total: \$1,061,284,440 Ticket promedio: \$3,536.60 Calificación promedio: 3.62/5 Reporte Analítico de E-Commerce en Colombia (2022-2023) 1. ESTADÍSTICAS DESCRIPTIVAS Métricas globales del negocio

- Total de órdenes: 300,000
- Ingreso total: \$1,061,284,440
- Ticket promedio: \$3,536.60
- Calificación promedio: 3.62 / 5

Análisis de tendencia central y dispersión por categoría El análisis muestra que la categoría de Electrónica es la más rentable, generando el mayor ingreso total, mientras que Juguetes es la menos rentable en términos de ingresos. 2. PATRONES Y HALLAZGOS CLAVE Categorías más y menos rentables

- Más rentables: Electrónica (\$265,553,143.55), Ropa (\$210,705,491.92)
- Menos rentables: Juguetes (\$53,133,022.80), Libros (\$105,053,264.83)

Comportamiento geográfico de las ventas Las principales ciudades que contribuyen a las ventas son:

- Bogotá: 90,198 órdenes, \$318,612,372.30
- Medellín: 59,728 órdenes, \$211,126,595.12
- Cali: 45,083 órdenes, \$159,816,821.91

Esto indica que las ventas están concentradas en las grandes ciudades, lo que podría sugerir una estrategia de marketing más focalizada en estas áreas. Preferencias de pago de los consumidores colombianos Los métodos de pago más utilizados son:

- Tarjeta: 104,884 órdenes, \$371,261,071.99 (34.96%)
- PSE: 74,936 órdenes, \$264,405,922.94 (24.98%)

Esto sugiere que la mayoría de los consumidores prefieren métodos de pago digitales, lo que puede ser una oportunidad para mejorar la experiencia de compra en línea. Tendencias temporales (estacionalidad, crecimiento) La evolución mensual muestra fluctuaciones en el número de órdenes y el ingreso total. Por ejemplo, en enero de 2023, se registraron 12,904 órdenes con un ingreso de \$45,526,625.44, mientras que en diciembre de 2022, se registraron 12,698 órdenes con un ingreso de \$44,928,538.05. Esto indica una tendencia de crecimiento en el primer mes del año. 3. ANÁLISIS DE CALIDAD DEL SERVICIO Relación entre estado de envío y calificación del cliente

- Entregado: 215,906 órdenes, calificación promedio de 3.62
- En camino: 45,202 órdenes, calificación promedio de 3.62
- Pendiente: 23,792 órdenes, calificación promedio de 3.62
- Cancelado: 15,100 órdenes, calificación promedio de 3.63

La calificación promedio es bastante consistente entre los diferentes estados de envío, lo que sugiere que la calidad del servicio no varía significativamente con el estado de envío. Categorías con mejor y peor satisfacción Las categorías con mejor calificación promedio son:

- Deportes: 3.63
- Belleza: 3.63

Las categorías con menor calificación son:

- Libros: 3.61
- Juguetes: 3.61

Esto puede indicar que hay oportunidades para mejorar la satisfacción del cliente en las categorías de libros y juguetes. 4. SUGERENCIAS DE VISUALIZACIÓN Gráficos útiles para comunicar estos datos

- Gráfico de barras para mostrar el ingreso total por categoría.
- Mapa de calor para visualizar el comportamiento geográfico de las ventas.
- Gráfico de líneas para mostrar la evolución mensual de órdenes e ingresos.

Métricas a priorizar en un dashboard ejecutivo

- Ingreso total por categoría
- Ticket promedio por categoría
- Calificación promedio por estado de envío
- Distribución de métodos de pago

5. CONCLUSIONES Y RECOMENDACIONES Recomendaciones concretas basadas en los datos 1. Focalizar campañas de marketing en las ciudades con mayor volumen de ventas (Bogotá, Medellín y Cali) para maximizar el retorno de inversión. 2. Optimizar la experiencia de pago en línea, considerando el alto uso de tarjetas y PSE, y explorar la posibilidad de ofrecer más opciones de pago. 3. Mejorar la satisfacción del cliente en las categorías de libros y juguetes, analizando las quejas y comentarios para identificar áreas de mejora. 4. Implementar estrategias de retención para clientes que han realizado compras con descuento, dado que el porcentaje de órdenes con descuento es significativo en todas las categorías. 5. Monitorear la estacionalidad en las ventas para ajustar la oferta de productos y promociones en meses clave, como enero y diciembre. Oportunidades de mejora identificadas


- Aumentar la visibilidad de las categorías menos rentables mediante promociones específicas.
- Evaluar la logística de envío para reducir el número de órdenes en estado "Pendiente" y "Cancelado", mejorando así la experiencia del cliente.

Este reporte proporciona un análisis exhaustivo del comportamiento de las ventas en el e-commerce colombiano, ofreciendo información valiosa para la toma de decisiones estratégicas.

## 4. VISUALIZACIONES


Las siguientes figuras fueron generadas replicando el estilo del dashboard interactivo construido en Streamlit con Plotly.

### Ingresos por categoría [↔](#)



**Figura 1.** Ingresos totales por categoría de producto (2022-2023).

### Métodos de pago [↔](#)



**Figura 2.** Distribución porcentual de métodos de pago.

### Evolución mensual de órdenes



Figura 3. Volumen de órdenes por estado de envío.

### Estados de envío




Figura 4. Evolución mensual del número de órdenes (2022-2023).

Tabla 1  
Resumen estadístico por categoría de producto

| Categoría   | Órdenes | Ingreso  | Ticket prom. | Calificación |
|-------------|---------|----------|--------------|--------------|
| Electronica | 74,953  | \$265.6M | \$3,543      | 3.62/5       |
| Ropa        | 59,599  | \$210.7M | \$3,535      | 3.62/5       |
| Deportes    | 45,322  | \$160.7M | \$3,547      | 3.63/5       |
| Hogar       | 45,093  | \$159.1M | \$3,529      | 3.62/5       |
| Belleza     | 30,096  | \$107.0M | \$3,554      | 3.63/5       |
| Libros      | 29,909  | \$105.1M | \$3,512      | 3.61/5       |
| Juguetes    | 15,028  | \$53.1M  | \$3,536      | 3.61/5       |

## 5. COMENTARIOS Y APORTES DEL ESTUDIANTE

Al revisar el reporte generado por el modelo, lo primero que llamó la atención fue la consistencia en la calificación promedio: todas las categorías y estados de envío rondan exactamente 3.62 sobre 5. En un principio parecía un error, pero al revisar la distribución del dataset se entiende que es resultado de la naturaleza sintética de los datos, donde las calificaciones siguen una distribución uniforme. Este punto es importante al interpretar los resultados: los patrones de satisfacción no reflejan comportamientos reales de consumidores, y el modelo LLM no detectó esta anomalía, lo que demuestra que el juicio humano sigue siendo indispensable.

Lo que sí resulta coherente con la realidad colombiana es la concentración geográfica de las ventas. Que Bogotá represente casi el 30% de las órdenes (90,198) y lidere en ingresos (\$318,6 millones) es comprensible dado que es la ciudad con mayor poder adquisitivo y penetración de internet del país. Medellín y Cali suman otro 35% del total, lo cual refleja que las estrategias de e-commerce en Colombia siguen siendo principalmente urbanas, dejando un mercado potencial importante en ciudades intermedias.

El dominio de la categoría Electrónica (\$265,5 millones, 25% del ingreso total), seguida de Ropa, refleja lo que se observa en plataformas reales como Mercado Libre o Falabella Colombia. En contraste, Juguetes aparece muy por debajo (\$53 millones), lo que sugiere que este segmento aún no ha madurado del todo en el canal digital o que los compradores prefieren ver estos productos físicamente antes de adquirirlos.

Respecto a los métodos de pago, el 35% de preferencia por tarjeta y el 25% por PSE confirman que el consumidor colombiano confía en los pagos digitales. Sin embargo, que Nequi represente solo el 10.1% resulta bajo considerando su crecimiento en años recientes; en un dataset real de 2025 ese porcentaje seguramente sería mayor.

Desde el punto de vista técnico, implementar este sistema combinando PySpark, la API de OpenAI y Streamlit fue un ejercicio muy valioso. La capacidad del LLM para estructurar un reporte coherente a partir de tablas de datos en cuestión de segundos es notable. No obstante, sus limitaciones también son evidentes: al no cuestionar la uniformidad de las calificaciones, presentó

ese patrón como un hallazgo positivo cuando en realidad es una característica artificial del dataset. Esto refuerza que la IA generativa es una herramienta de apoyo poderosa, pero no reemplaza el criterio analítico del profesional.

## **6. CONCLUSIONES**

La integración de modelos de lenguaje con pipelines de Big Data demuestra ser una herramienta poderosa para la analítica automatizada. El sistema procesó 300,000 registros, calculó agregaciones estadísticas y generó un reporte interpretativo en segundos.

Las métricas globales (ingreso total de \$1,061M, ticket promedio de \$3,537 y tasa de entrega exitosa del 72%) confirman un mercado activo con oportunidades en logística y diversificación geográfica.

Sin embargo, el modelo no detectó la uniformidad artificial en las calificaciones, lo que confirma que el criterio humano sigue siendo esencial para validar los resultados generados por IA. La arquitectura Big Data + LLM + visualización interactiva es replicable y escalable para proyectos reales de analítica empresarial.